Parallel

Longest Common Subsequence

平行最長共同子字串

R04922067 楊翔雲, Morris

NTU CSIE

Longest Common Subsequence

- 在兩個序列中找到最長共同子序列
- 給定兩個字串 $X=x_1x_2\cdots x_n$, $Y=y_1y_2\cdots y_m$
- 位置序列 $S = s_1 s_2 \cdots s_r, \ \forall i < r : s_i < s_{i+1}$
- ・生成字串 $C(X,S)=c_1c_2\cdots c_r$, 其中 $c_i=x_{s_i}$
- ・目標找到 |S| 最大・且滿足 $C(X,S_x)=C(Y,S_y)$

Recursive Formula

$$L[i,j] = \left\{egin{array}{ll} L[i-1,j-1]+1 & , \ if x_i = y_j \ \max\{L[i-1,j],L[i,j-1]\} & , \ if x_i
eq y_j \ , \ otherwise \end{array}
ight.$$

Naive Implementation

- 時間複雜度 O(nm),空間複雜度 O(nm)
- 回溯法 (backtracking) 找解

Recursive Formula

$$L[i,j] = \left\{egin{array}{ll} L[i-1,j-1]+1 & , \ if \ x_i = y_j \ \max\{L[i-1,j],L[i,j-1]\} & , \ if \ x_i
eq y_j \ , \ otherwise \end{array}
ight.$$

Advanced Implementation

- Multiple buffering、滾動數組
- 時間複雜度 O(nm),空間複雜度 $O(\min(n,m))$
- 如何找到一組解?Hirschberg's Algorithm

Advanced Algorithm

O(nm) 不是最好的!我們可以做到 $O(rac{nm}{\log n})$ 。

How to Do

- Method of Four Russians 四個俄羅斯人算法
- 這只是一種技術 藉由預建表達到加速
- 建表空間 $O(n^{1.5})$

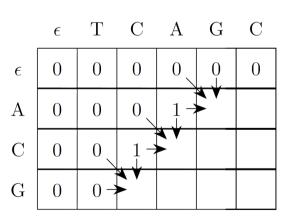
儘管能壓縮表格,查表效能好嗎?Mind the Cache!

Data Dependency

根據遞迴公式,所有情況依賴左、上、左上三格

$$L[i,j] = \left\{egin{array}{ll} L[i-1,j-1]+1 &, \ if \ x_i = y_j \ \max\{L[i-1,j],L[i,j-1]\} &, \ if \ x_i
eq y_j \ 0 &, \ otherwise \end{array}
ight.$$

	ϵ	Τ	С	A	G	С
ϵ	0	0	0	0	0	0
A	0	0	0	1	1	1
\mathbf{C}	0	0	1	1	1	2
G	0	0	1	1	2	2



How to Parallel LCS?

Wavefront Method 波前法:

平行處理波上的資料,如下圖 t_i 表示第i次運行。當矩陣為n imes m時,運行n+m-1次。

Efficiency

同一個演算法,效能天差地遠

提高資料局部性

Enhanced Data Locality

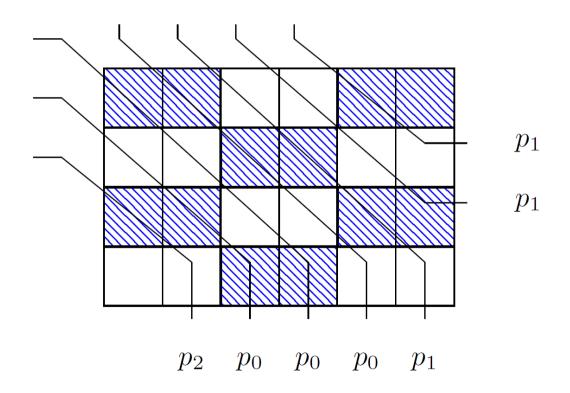
減少通信成本

Reduce Communication Costs

Efficiency - Problem

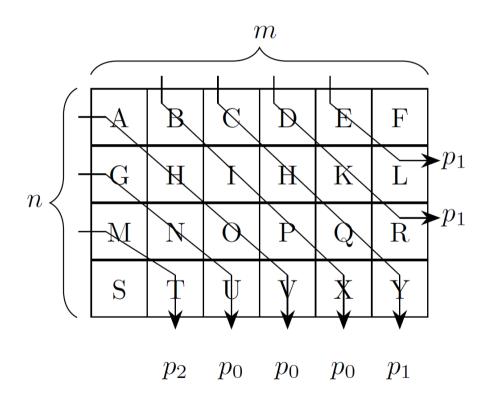
假設每-1 imes2 的區塊為-個 page size

造成不同的處理器會使用同一個 page ⇒ false sharing

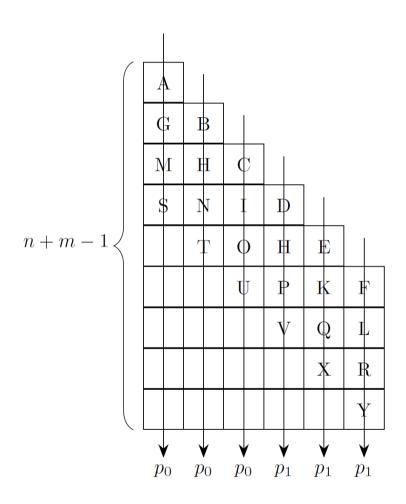


Efficiency - Data Layout

換個排列就會好了些 ... 但仍需要 n+m-1 次



Efficiency - Data Layout



Take a Break

假設我們有 10 個處理器

 $10 \times$ faster

運行長度 $n=m=10^6$,單一處理器約為 $4096 \mathrm{\ s}$

現在約為 512 s

Do it Better

有沒有可能少於 n+m-1 次完成?可以,我們改公式吧!

 $C = \Sigma = \mathtt{ACGT}$:字元集

P[i,j]: 對字元 c_i · 位置 j 之前(包含)出現 c_i 的位置。

$$P[i,j] = \left\{ egin{array}{ll} 0 & , \ if \ j = 0 \ j & , \ if \ y_j = c_i \ P[i,j-1] & , \ o.w. \end{array}
ight.$$

這一步可以平行嗎?可以

- O(|C|m/p+m):每個字元獨立
- $O(|C|m/p + \log m)$: 倍增找解

Doubling Algorithm

倍增算法,找到最靠近該位置的最近匹配位置

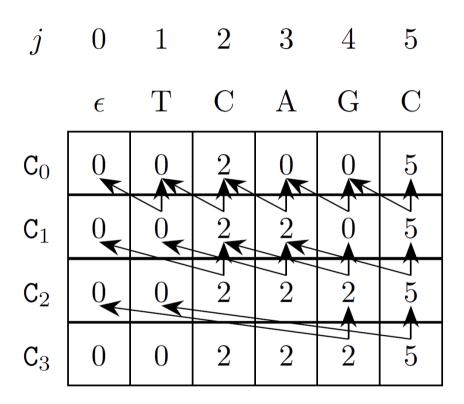
$$P[i,j,0] = \left\{ egin{array}{ll} 0 & & , if y_j
eq c_i \ j & & , if y_j = c_i \end{array}
ight.$$

$$P[i,j,k] = \max\{P[i,j,k-1], P[i,j-2^{k-1},k-1]\}$$

- Serial algorithm $O(|C|m\log m)$
- Parallel algorithm $O(|C|m\log m/p + \log m)$

空間只需要O(m),我們只需要最後那一排。

Doubling Algorithm - Practice



Practice - P[i,j]

$$X = \mathtt{ACG}, Y = \mathtt{TCAGC}$$

j	0	1	2	3	4	5
	ϵ	${ m T}$	\mathbf{C}	A	G	С
Α	0	0	0	ಌ	ಌ	3
С	0	0	2	2	2	5
G	0	0	0	0	4	4
Т	0	1	1	1	1	1

Recursive Formula

每次迭代 $c=x_i$

$$L[i,j] = \left\{egin{array}{ll} 0 & ext{, } \emph{if } i=0 \emph{ or } j=0 \ L[i-1,j] & ext{, } \emph{if } P[c,j]=0 \end{array}
ight.$$

$$L[i,j] = \max\{L[i-1,j], L[i-1,P[c,j]-1]+1\}$$

與先前一樣,同時拔除尾端找子問題的最佳解

保證匹配 x_i 和 $y_{P[c,j]}$ · 而非 x_i 和 y_j 是否匹配

- ・L[i,j] 需 O(nm/p+n)P[i,j] 需 $O(|C|m/p+\log m)$
- 最後得到 $O(n + \log m)$

Recursive Formula - Compare

保證匹配 x_i 和 $y_{P[c,j]}$ · 而非 x_i 和 y_j 是否匹配 ?

LCS(TCAG, AC)

- 一般做法,在下述兩種情況找最佳解
 - \circ LCS(TCAG, A)
 - \circ LCS(TCA, AC)
- 現在可以這麼找
 - \circ LCS(TCAG, A)
 - $_{\circ}$ LCS(T, A) + C

Practice - L[i,j]

 $X = \mathtt{ACG}, Y = \mathtt{TCAGC}$

j	0	1	2	3	4	5
	ϵ	${ m T}$	\mathbf{C}	A	G	\mathbf{C}
Α	0	0	0	ಌ	က	3
С	0	0	2	2	2	5
G	0	0	0	0	4	4
Т	0	1	1	1	1	1

j	0	1	2	3	4	5
	ϵ	${ m T}$	\mathbf{C}	A	G	\mathbf{C}
ϵ	0	0	0	0	0	0
A	0	0	0	1	1	1
С	个	7			7	7
G						

Take a Break

降低 critial path 長度,屬於 常數優化

2 imes faster

現在約為 256 s

Level Parallelism

- Bit-level parallelism 位元同時計算,如位元壓縮之類的算法設計
- Instruction-level parallelism 編譯器、硬體,可藉由 instruction scheduling 增加平行度
- Memory-level parallelism 現在位置
- Task parallelism
 將問題一分為多,分別處理好再合併

Back to Bit-level

- 之前所講的都是在一次運算只對一個數據 L[i,j] 操作
- 若一次運算對 w 個數據操作,其 w 為硬體的平行度
 - 。如 $L[i,j],\; L[i,j+1],\; \cdots,\; L[i,j+w-1]$
 - 。當代 64-bit 架構,單一處理器能快上 60 个倍

How to Do?

The Art of the Algorithm

Bit-level - Introdution

因 L[i,j] 與其相鄰格子差值至多為 1

轉換成 k-dominant matches boudaries,找出有多少條

Bit-level - CIPR Algorithm

分成 m+1 個階段 L_0,L_1,L_2,\cdots,L_m

以 0 表示可以傳遞 L_j 至 $L_{j+1} \cdot L_2 = exttt{101} \cdot L_3 = exttt{110} \dots$

Bit-level - CIPR Algorithm

運算 L_j 至 L_{j+1} · Crochemore 給出下列公式

$$L_0=2^n-1$$

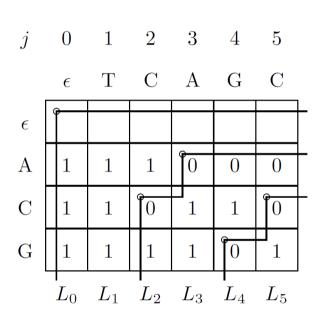
$$L_j = (L_{j-1} + (L_{j-1} ext{ AND } M[y_j])) ext{ OR } (L_{j-1} ext{ AND } M'[y_j])$$

- $M[y_j]$ 字元 y_j 匹配字串 X 組成的位向量 \cdot 0 為未匹配 \cdot 1 為匹配
- L_{j-1} AND $M[y_j]$ 為下一階段可行的 k-dominant 位置,以 1 表示可行解
- $L_{j-1}+(L_{j-1} ext{ AND } M[y_j])$ 利用加法進位的性質·將連續可行解移除掉
- OR $(L_{j-1} AND M'[y_j])$ 進位造成錯誤,用其修正之

Practice

$$M[\mathtt{A}] = \mathtt{OO1} \cdot M[\mathtt{C}] = \mathtt{O10} \cdot M[\mathtt{G}] = \mathtt{100} \cdot M[\mathtt{T}] = \mathtt{000}$$

- $L_1 = 111$
- L_1 AND M[C]=010 支配點的可行解 出現 1 的位置可成為新的支配點
- L_1 AND M'[C]=101 修正遮罩 出現 1 的位置不可成為支配點
- 111 + 010 = <u>1</u>001
 進位來移動支配線
 因 <u>溢位</u> 多紀錄一條
- $L_2 =$ 001 OR 101 =101



Bit-level + Memory-level

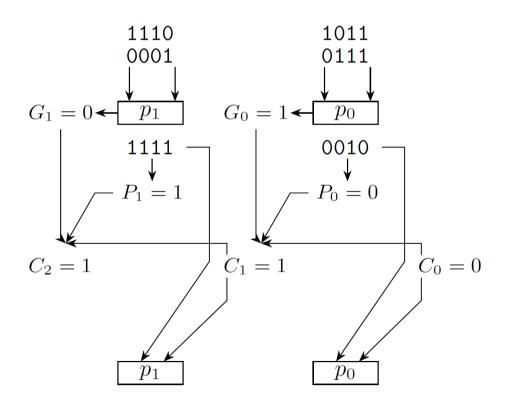
平行加法器於多處理器平台上,需要複習以下幾種加法器

- Ripple-carry Adder
- Carry-lookahead Adder
- Carry-select Adder
- More ...

Carry Adder

利用 $C_{i+1} = G_i + P_i \; C_i$ 、切數個區塊加法,O(n/p+p)

1110 1011 + 0001 0111 = $\underline{1}$ 0000 0010



Take a Break

支援 64-bit 操作的計算機,增添 64 倍的效能改善

128 imes faster

現在約為4s

已經很完美了嗎?No

Back to Task

當平行遇到了瓶頸

一次能平行處理的資料數不夠多,如何拓展更高的平行度?

先決條件: 是否可在合併 Task 階段使用高效率的平行

Task-level - Introduction

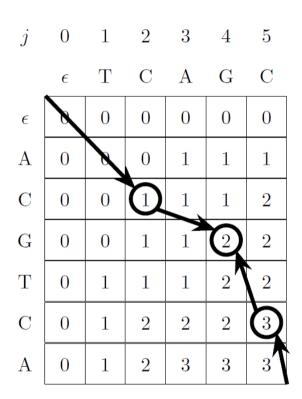
將 X 拆成前半 X_{front} 和後半 X_{back} $\mathrm{LCS}(X,Y) = \mathrm{merge}(\mathrm{LCS}(X_{\mathrm{front}},Y),$ $\mathrm{LCS}(\mathrm{reverse}(X_{\mathrm{back}}),\mathrm{reverse}(Y)))$

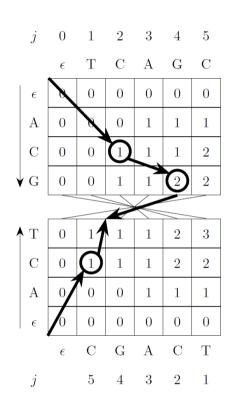
Task-level - Merge Task

j	0	1	2	3	4	5
	ϵ	Τ	\mathbf{C}	A	G	С
ϵ	0	0	0	0	0	0
A	0	0	0	1	1	1
С	0	0	1	1	1	2
G	0	0	1	1	2	2
T	0	1	1	1	2	2
С	0	1	2	2	2	3
A	0	1	2	3	3	3

j	0	1	2	3	4	5
	ϵ	Τ	С	A	G	\mathbf{C}
$\mid \epsilon$	0	0	0	0	0	0
A	0	0	0	1	1	1
C	0	0	1	1	1	2
∀ G	0	0	1	1	2	2
			\Rightarrow			
\uparrow T	0	1	1	1	2	3
$\uparrow T \\ C$	0	1	1	1	2	3
C	0	1	1	1	2	2
$egin{array}{c} \mathbf{C} \\ \mathbf{A} \end{array}$	0	1 0	1 0	1	2	2

Task-level - Why





Take a Break

現在,我們能拆成至少2個階段

2 imes faster

現在約為2s

這已經是最快了嗎?還沒呢

Instruction-level parallelism

先不談指令平行

由於 shared memory 的關係,編譯器大多不做優化

你可以做到

- Copy optimization
- Improve hardware prediction
- Memory coalesce
- More ... 你可以修 **高等編譯器**

Instruction-level SIMD

- MMX/SSE/AVX
- Vectorization vs. Parallelization

Submit Your Best Algorithm

如果是妳的話,能給我更多啟發對吧?

- 批改娘 10110. Longest Common Subsequence
- 批改娘 10111. Longest Common Subsequence II
- 批改娘 20012. Bit Vector Adder
- Coming Soon

Reference

- Jiaoyun Yang, Yun Xu, Yi Shang, "An Efficient Parallel Algorithm for Longest Common Subsequence Problem on GPUs", 2010
- Maxime Crochemore, Costas S. Iliopoulos, Yoan J. Pinzón, James F. Reid, "A fast and practical bit-vector algorithm for the Longest Common Subsequence problem", 2001
- Maxime Crochemore, Costas S. Iliopoulos, Yoan J. Pinzón, "Speeding-up Hirschberg and Hunt-Szymanski LCS Algorithms", 2001